

Explorando o Potencial do AWS SageMaker

Cassiano Peres
Analista de Sistemas

Mais sobre mim

- CTO – Arabyka e Brexbit
- Graduado em TADS 2015
- Pós-graduando em Defesa Cibernética
- Apaixonado pela liberdade e descentralização
- Github: cassianobrexbit
- Linkedin: peres-cassiano

Desafio da Live

Hoje vamos explorar alguns potenciais de uso AWS SageMaker, um serviço totalmente gerenciado da AWS, para preparar, criar, treinar e implantar modelos de Machine Learning (ML) de alta qualidade rapidamente, de forma totalmente gerenciada.

Percurso

Etapa 1

Contexto de ML

Etapa 2

Explorando o potencial do AWS SageMaker

Etapa 3

Prática com Sagemaker Studio

Requisitos

- ✓ Conta ativa na AWS
- ✓ Fundamentos de ML
- ✓ Fundamentos de programação em Python
- ✓ Vontade e curiosidade

Machine learning

- IA e ML não são apenas sobre robôs e ficção científica
- Estão em todos os lugares, por exemplo:
 - Motor de buscas do Google
 - Sistema de recomendações da Amazon
 - Reconhecimento facial do Facebook.



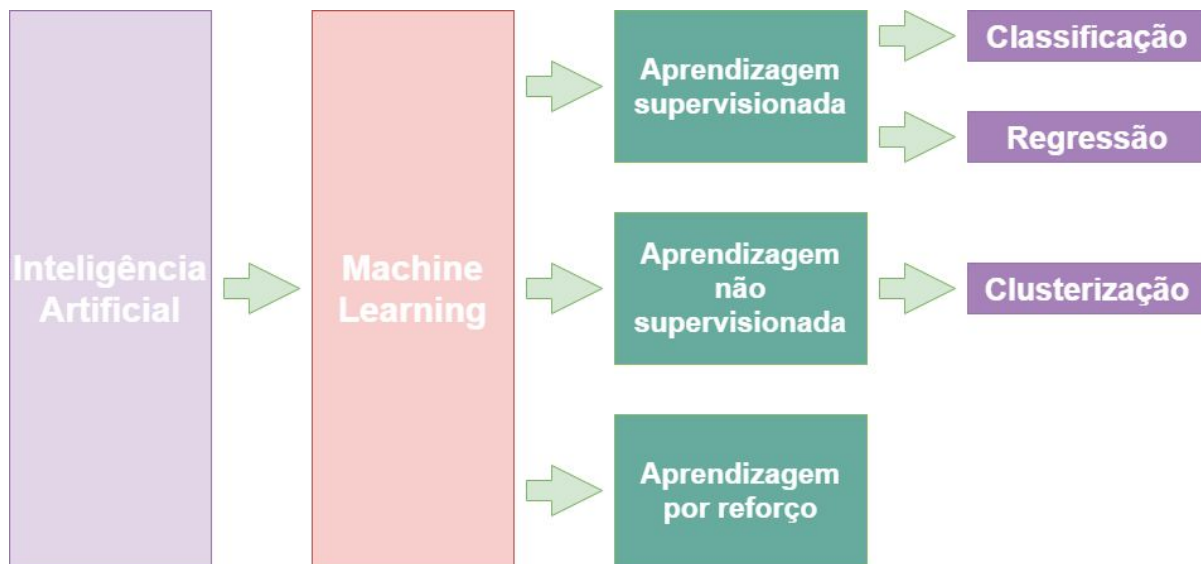
Machine learning

- Possuem três componentes básicos



Machine learning

- Panorama geral



Machine learning

- Onde podemos encontrar dados?
 - Kaggle
 - UCI
 - AWS Dataset
 - ImageNet

AWS SageMaker

- Uma plataforma de fluxo de trabalho de ML totalmente gerenciada.
- Permite criar modelos escalonáveis de AI / ML com facilidade e eficiência.
- Permite criar modelos escaláveis de AI / ML com facilidade e eficiência.



DIGITAL
INNOVATION
ONE

AWS SageMaker

Amazon SageMaker

Prepare →

SageMaker Ground Truth
Label training data for machine learning

SageMaker Data Wrangler NEW
Aggregate and prepare data for machine learning

SageMaker Processing
Built-in Python, BYO R/Spark

SageMaker Feature Store NEW
Store, update, retrieve, and share features

SageMaker Clarify NEW
Detect bias and understand model predictions

Build →

SageMaker Studio Notebooks
Jupyter notebooks with elastic compute and sharing

Built-in and Bring-your-own Algorithms
Dozens of optimized algorithms or bring your own

Local Mode
Test and prototype on your local machine

SageMaker Autopilot
Automatically create machine learning models with full visibility

SageMaker JumpStart NEW
Pre-built solutions for common use cases

Train & tune →

One-click Training
Distributed infrastructure management

SageMaker Experiments
Capture, organize, and compare every step

Automatic Model Tuning
Hyperparameter optimization

Distributed Training Libraries NEW
Training for large datasets and models

SageMaker Debugger NEW
Debug and profile training runs

Managed Spot Training
Reduce training cost by 90%

Deploy & manage →

One-click Deployment
Fully managed, ultra low latency, high throughput

Kubernetes & Kubeflow Integration
Simplify Kubernetes-based machine learning

Multi-Model Endpoints
Reduce cost by hosting multiple models per instance

SageMaker Model Monitor
Maintain accuracy of deployed models

SageMaker Edge Manager NEW
Manage and monitor models on edge devices

SageMaker Pipelines NEW
Workflow orchestration and automation

SageMaker Studio

Integrated development environment (IDE) for ML




DIGITAL
INNOVATION
ONE

Componentes Chaves

- **Amazon Simple Storage Service S3:** Serviço de storage de dados, data lake
- **Amazon Elastic Compute Cloud:** Serviço de instâncias de máquinas virtuais escalável para provisionamento de computação



AWS SageMaker



Treinamento

- **Algoritmos providos pel AWS Sagemaker:** Linear Learner Algorithm and the XGBoost Algorithm, K Means, Principal Component Analysis, image classification, LDA, Sequence to Sequence Algorithm
- **Amazon MarketPlace:** algoritmos disponíveis em <https://aws.amazon.com/marketplace/solutions/machine-learning>



Treinamento

- **APACHE SPARK:** utilizados para treinar modelos de ML
- **Frameworks populares:** Códigos baseados em Python com TensorFlow ou Apache MXNet
- **Códigos personalizados:** utilizando containers Docker e seu path podem ser providos por uma chamada no Amazon SageMaker CreateTrainingJob API

Deploy

Depois de treinado, um modelo de ML pode ser publicado (deployed) das seguintes formas

- Para uma predição por vez (hosting)
- Para múltiplas predições (batch)

Deploy

- **Inference Pipeline:** ferramentas para transformação em lotes de dados em formato de *pipeline*
- **Batch Transform:** Pré-processamento de datasets extensos
- **Automatic Scaling:** ajusta o número de instâncias dinamicamente de acordo com a demanda
- **Elastic Inference:** acelera a inferência e reduz a latência
- **Neo:** treina modelos e otimiza para hardwares específicos

Mãos à obra!

Desafio da Live

Vamos utilizar o **Amazon SageMaker Random Cut Forest (RCF)**, um algoritmo projetado para detectar pontos de dados anômalos em um conjunto de dados.

Exemplos de anomalias:

- atividade de um site que aumenta de forma não característica
- dados de temperatura divergentes de um comportamento periódico
- alterações no número de passageiros do transporte público refletem a ocorrência de um evento especial.

Desafio da Live

Nesta Live vamos treinar um modelo RCF no conjunto de dados *Numenta Anomaly Benchmark (NAB) NYC Taxi*, que registra a quantidade de viagens de táxi da cidade de Nova York ao longo de seis meses. Em seguida, o modelo irá prever eventos anômalos, emitindo uma "pontuação de anomalia" para cada ponto de dados.

Etapas

- Obter, transformar e armazenar dados para uso no Amazon SageMaker
- Criar um job de treinamento AWS SageMaker em um conjunto de dados para produzir um modelo RCF
- Utilizar o modelo RCF para realizar inferência com um endpoint Amazon SageMaker

Dicas de desafios

- Testar com outros modelos de ML
- Testar com outros tipos de problemas
- Utilizar outros conjuntos de dados
- Explorar os recursos do AWS SageMaker

Dúvidas?



Referencial

- <https://aws.amazon.com/sagemaker/>
- https://docs.aws.amazon.com/pt_br/quicksight/latest/user/what-is-random-cut-forest.html
- Repositório:
<https://github.com/cassianobrexbit/dio-live-sagemaker-20082021/blob/master/README.md>